



教育背景

上海海洋大学（双一流） 计算机类（空间信息与数字技术） | 本科

2023.09 - 预计 2027.06

项目经历

XEYO - 桌面 Agent 引擎 独立开发

2026.05 - 2026.07

从零实现桌面 Agent 引擎，支持多会话、后台任务、工具调用、权限控制和长任务执行。

技术栈：Python / FastAPI / Tauri / React / pytest

- 任务执行**：搭建逐题轨迹与 verifier 复盘流程，验证引擎对复杂编码任务的提升；官方中立 scaffold 在 32 道题上 157 次 trial 均未通过，XEYO 通过其中 **13 道 (40.6%)**。
- 上下文管理**：将用户输入、引擎状态和系统事件分层处理，减少重复注入对上下文的影响；基于 28 天、9,144 次调用的真实账本，长上下文缓存命中率中位数达到 **98.54%**。
- 多代理协作**：设计子代理独立循环与独立存储，共享父级取消信号并隔离中间过程；主代理只接收结算结果，工具面按任务裁剪后下发。
- 安全与恢复**：将权限裁决、内容寻址快照和条件回滚接入统一执行流程；授权指纹不包含模型可控参数，文件状态不一致时拒绝强制覆盖，支持冲突检测与幂等重试。
- 开发工具优化**：实现 AST 符号索引，为代码读取提供按函数定位能力；单个函数读取量由 **20,523 降至 206 token**，符号召回率达到 **100%**，高于正则检索的 51%。

RXY-Agent - Java RAG 知识库系统 独立开发

2026.04 - 2026.05

面向企业知识库场景实现 RAG 系统，覆盖文档 ETL、混合检索、证据判断、权限过滤和性能优化。

技术栈：Java 21 / Spring Boot / Milvus / Kafka / Redis / Neo4j

- 知识入库**：使用 Tika 解析文档，完成标题感知分块、上下文增强和双向量入库；将 ACL 位图下推至 Milvus 查询层，未授权内容不进入候选集。
- 检索优化**：将文档名和章节路径加入重排输入，结合文档级置信度门控与向量、重排、BM25 融合；黄金集 20 例平均 Precision 从 **0.769 提升至 0.954**（含一次 embedding 升级），同主题文档混淆残余降至 2 例。
- 回答与记忆**：设计无需 LLM 的证据充分性判断、免 LLM 重检索和记忆分流流程，对知识问答、用户记忆和库外问题分别处理，减少检索不足时的直接生成与一刀切拒答。
- 性能优化**：通过虚拟线程、实体缓存、连接池调整和 rerank 结果缓存定位并缓解高并发瓶颈；200 并发下服务端检索 p95 从 **2,222ms 降至 404ms**。

专业技能

语言与后端：Java、Python、Spring Boot、FastAPI、MySQL、Redis、Kafka

Agent 开发：Agentic Loop、Tool Calling、LangGraph、MCP、Human-in-the-Loop

RAG 与 LLM：Milvus、混合检索、Rerank、Function Calling、提示词工程、流式输出

工程与安全：Docker、pytest、链路追踪、权限裁决、提示注入防御